SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

Evidenčné číslo: FEI-100863-111119

POROVNANIE SPRACOVANIA 3D DÁT ANALYTICKÝM METÓDAMI A NEURÓNOVÝMI SIEŤAMI

BAKALÁRSKA PRÁCA

2023 **Maroš Kocúr**

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

Evidenčné číslo: FEI-100863-111119

POROVNANIE SPRACOVANIA 3D DÁT ANALYTICKÝM METÓDAMI A NEURÓNOVÝMI SIEŤAMI

BAKALÁRSKA PRÁCA

Študijný program:	Robotika a kybernetika
Názov študijného odboru:	kybernetika
Školiace pracovisko:	Ústav robotiky a kybernetiky
Vedúci záverečnej práce:	prof. Ing. Jarmila Pavlovičová, PhD.
Konzultant:	Ing. Miroslav Kohút

Bratislava 2023 **Maroš Kocúr**

Slovenská technická univerzita v Bratislave
Ústav robotiky a kybernetiky

Fakulta elektrotechniky a informatiky
2022/2023

ZADANIE BAKALÁRSKEJ PRÁCE

Autor práce:	Maroš Kocúr
Študijný program:	robotika a kybernetika
Študijný odbor:	kybernetika
Evidenčné číslo:	FEI-100863-111119
ID študenta:	111119
Vedúci práce:	Ing. Miroslav Kohút
Vedúci pracoviska:	prof. Ing. Jarmila Pavlovičová, PhD.
Miesto vypracovania:	Ústav robotiky a kybernetiky
Názov práce:	**Porovnanie spracovania 3D dát analytickými metódami a neurónovými sieťami**
Jazyk, v ktorom sa práca vypracuje:	slovenský jazyk
Špecifikácia zadania:	Na základe rastúcej potreby práce s 3D dátami dochádza k neustálemu testovaniu a výskumu nových možností algoritmov. Súčasná práca sa venuje algoritmu RANSAC pomocou ktorého je možné matematicky opísať rôzne zoskupenia bodov. Modely je následne možné použiť pri ďalšom spracovaní 3D dát. Cieľom práce je porovnať analytickú metódu implementácie RANSAC modelu s jeho rozšírením, ktoré implementuje aj modely neurónových sietí na dosiahnutie lepších výsledkov. Úlohy: 1. Popíšte a analyzujte základnú problematiku práce s 3D dátami a neurónovými sieťami. 2. Analyzujte algoritmus RANSAC a možnosti jeho rozšírenia pomocou NN modelu. 3. Implementujte vami vybrané algoritmy. 4. Otestujte implementované algoritmy na zvolených dátach. 5. Zdokumentujte a vyhodnoťte výsledky.
Termín odovzdania práce:	02. 06. 2023
Dátum schválenia zadania práce:	**12/08/2022**
Zadanie práce schválil:	**doc. Ing. Eva Miklovičová, PhD.** garantka študijného programu

SÚHRN

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE
FAKULTA ELEKTROTECHNIKY A INFORMATIKY

Študijný program:	Robotika a kybernetika
Autor:	Maroš Kocúr
Bakalárska práca:	Porovnanie spracovania 3D dát analytickým metódami a neurónovými sieťami
Vedúci záverečnej práce:	prof. Ing. Jarmila Pavlovičová, PhD.
Konzultant:	Ing. Miroslav Kohút
Miesto a rok predloženia práce:	Bratislava 2023

Na základe rastúcej potreby práce s 3D dátami dochádza k neustálemu testovaniu a výskumu nových možností algoritmov. Súčasná práca sa venuje algoritmu RANSAC pomocou, ktorého je možné matematicky opísať rôzne zoskupenia bodov. Modely je následne možné použiť pri ďalšom spracovaní 3D dát. Cieľom práce je porovnať analytickú metódu implementácie RANSAC modelu s jeho rozšírením, ktoré implementuje aj modely neurónových sietí na dosiahnutie lepších výsledkov.

Kľúčové slová: RANSAC, PCL, neurónová sieť

ABSTRACT

SLOVAK UNIVERSITY OF TECHNOLOGY IN BRATISLAVA
FACULTY OF ELECTRICAL ENGINEERING AND INFORMATION TECHNOLOGY

Study Programme:	Robotics and cybernetics
Author:	Maroš Kocúr
Bachelor's thesis:	Comparison of 3D Data Processing by Analytical Methods and Neural Networks
Supervisor:	prof. Ing. Jarmila Pavlovičová, PhD.
Consultant:	Ing. Miroslav Kohút
Place and year of submission:	Bratislava 2023

Based on the growing need to work with 3D data, there is constant testing and research of new algorithm possibilities. The current work is devoted to the RANSAC algorithm, with the help of which it is possible to mathematically describe various groupings of points. The models can then be used for further processing of 3D data. The aim of the work is to compare the implementation of the analytical method of the RANSAC model with its extension, which also implements neural network models to achieve better results.

Keywords: RANSAC, PCL, neural network

Pod'akovanie

I would like to express a gratitude to my thesis supervisor.

Obsah

Úvod **1**

1 PCL **2**
1.1 Pouzitie . . . 2
1.2 Befor installation . . . 2
1.3 Inštalácia PCL . . . 2
1.4 Používanie PCL . . . 3
1.5 Kompilácia projektu . . . 3

2 Point Cloud **4**
2.1 General . . . 4
2.2 Pouzitie . . . 4
2.3 Konverzia do 3D povrchu . . . 4

3 Neural Network **5**
3.1 History . . . 5
3.2 What is it . . . 5
3.3 Vývoj . . . 5

4 RANSAC **6**
4.1 Overview . . . 6
4.2 Algoritmus . . . 6
4.3 RANSAC 3D . . . 7
4.4 Neural guided RANSAC . . . 7

5 KINECT **8**
5.1 Ako funguje . . . 8
5.2 Výstup z KINECTU . . . 8
5.2.1 List potrebných Knižnic pre Ubuntu 22.04 LTS . . . 9
5.3 OpenNI 2.0 . . . 9
5.4 PCD súbor . . . 9

6 Implementavanie RANSAC algoritmu **11**
6.1 1. PointCloudData . . . 11
6.2 2. Zvolenie geometrického modelu . . . 11
6.3 3. Definovanie parametrov . . . 11

6.4 4.implementovanie RANSACu 12
6.5 5. Vyzualizácia PointCloudu 14

7 Implementovanie RANSAC alfgoritmu s pouzitim NN **15**

8 Vystupy **16**
8.1 POZNAMKA 16

9 Recitácia **17**

10 Kod = neaktualne **18**

Záver **19**

Zoznam použitej literatúry **20**

Zoznam obrázkov a tabuliek

Obrázok 3.1 Priklad neuronovej siete 6
Obrázok 4.1 Priklad algoritmu v 2D rovine 7
Obrázok 5.1 Kinect v2 8
Obrázok 5.2 Architektúra softwarového vývoja 10
Obrázok 5.3 Výstupný Point Cloud z Kinectu 10
Obrázok 6.1 Dajake rovnice co treba prepocitat a prekreslit 12
Obrázok 8.1 Výstup algorimu RANSAC v knižnici PCL 16
Obrázok 8.2 Aktualny vystup z kinectu 17

Zoznam algoritmov

Zoznam výpisov

1 Vytvorenie PCD pomocou Kinectu 18

Úvod

V tejto prácy sa zameriame na vyhľadavanie rôzných tvarou v Point Cloude, ktorý si sami naskenujeme pomocou Kinect v2. Porovname algoritmus RANSAC do ktorého implementujeme neuronove siete a porovname efektivitu a presnosť tohto algoritmu. Taktiež sa naučíme pracovať s Point Cloud Library a hardwarom Kinect v2 na operačnom systéme Ubuntu 22.04 LTS.

1 PCL

PCL je samostný, vysoko škalovateľný, otvorený projekt pre 2D a 3D obrázky a spracovávanie point cloud. Knižnica je cross platform, napisana v jazyku C++ a Pythone. Najčastejšie sa používa na operačnom systéme Linux. Existujú package aj pre macOS a Windows vytvorené tretímy stranami. My v tomto projekte budeme používať Ubuntu 22.04. LTS a verzia PCL je 1.12.1. Knižnica ja vydana pod BSD licenciami čo znamená, že je voľne použiteľna úre komerčné účely a za účelom výskumu.[1]

1.1 Pouzitie

PCL je open-source knižnica s algoritmami pre point cloud spracovanie úloh a spracovanie 3D geometrie, aké sa vyskytuje v trojdimenzionálnom strojovom videní. Knižnica má algoritmy na filtrovanie, odhady funkzie, rekonštrukcie povrchov, 3D registracie, prispôsobenie modelu, vyhľadavanie objektov a segmentácie. PCL ma vlastný format na ukladanie point cloud dát - PCD, ale podporuje načítanie a ukladanie dát do rôznych iných formátov.[2] Algoritmy sa používajú na perception v robotike na filtrovanie zašumených dát, spájanie 3D dát, segmentovanie dôležitých Častí v priestore, extrahovanie kľučových bodovv a výpoČet deskriptorov na rozpoznávanie objektov vo svete na základe ich geometrického vzhľadu a vytvárať povrchy z point cloudu a vykreľovať ich.

1.2 Befor installation

PLC potrebuje niekoľko knižnic tretích strán na fungovanie, ktoré musia byť nainštalované. Väčšina matematických operácii je implementovaných v Eigen knižnici. Vizualizačný model pre 3D point cloudy je na základe VTK. Knižnica Boost je použitá na zdieľanie pointrov a FLANN knižnica pre rýchlé hľadanie v okolí na základe algoritmu k-nearest. Ďalej sme nainštalovali OpenNI 2 knižnicu, ktorá nám zabezpčuje komunikáciu s Kinectom2

1.3 Inštalácia PCL

PCL je dostupný na mnoho distribúcii Linuxu ako Ubuntu, Debian, Fedora, Gentoo a Arch Linux. PCL na distribúciach Ubuntu a Debian môžeme nainštalovať pomocou.

sudo apt install libpcl-dev

Na Windowse sa PCL inštaluje pomocou vpckg package manažéra vytvoreného Microsoftom.

PS> ./ vcpkg install pcl

MacOS ma Homebrew package manažéra ktorý podporuje inštaláciu packagov, ktoré Apple

alebo Linux nedokáže nainštalovať. brew install pcl Toto su odporúčane inštalacie pre PCL na daných operačných systémoch.

1.4 Používanie PCL

Na používanie PCL si potrebujeme v našom kóde vložiť potrebné knižnice. Po nainštalovaní sa v našom systéme nastavia premenné, takže stači nám použiť príkaz v C++, include <pcl/“názovknižnice“.h>.

1.5 Kompilácia projektu

Vytvoríme si súbor CMakeList.txt v ktorom zadefinujeme potrebné premenné aby make vedel najsť cestu ku knižnici a vedel aké súbory ma skompilovať. Ďalej vytvoríme priečinok s názvom build, v terminály vojdeme do neho a pomocou príkazu cmake “cesta k CMakeList.txt“, si vytvorime makefile. Ďalej používame len príkaz make ktorý nam vytvorí súbor pomocov ktorého môžeme spustiť projekt.

2 Point Cloud

2.1 General

Je to súbor bodov v priestore. Body môžu reprezentovať 3D tvary alebo objekty. Každý bod má karteziánske súradnice (X,Y,Z). Point cloud je generovaný pomocou 3D skenera alebo pomocou softwaru na fotogrametriu, ktorý meria veľa bodov na externom povrchu objektov okolo. My v tomto projekte použijeme Kinect 2 (odsek 6). Point cloud sa používa v 3D modelovaní, metrológii, meranie kvality výrobkov a rôzne vizualizácie. Point cloud sa často zarovnáva s 3D modelmi alebo inými point cloudmi ako registrácia množín bodov. [3]

2.2 Pouzitie

Pre priemyselnú metrológiu alebo inšpekciu pomocou priemyselnej počítačovej tomografie možno mračno bodov vyrobeného dielu zosúladiť s existujúcim modelom a porovnať, aby sa skontrolovali rozdiely. Geometrické rozmery a tolerancie možno získať aj priamo z point cloudu.

2.3 Konverzia do 3D povrchu

V geografických informačných systémoch sú point cloudi jedným zo zdrojov využívaných na tvorbu digitálneho výškového medelu terénu. Používajú sa aj na generovanie 3D modelov mestského prostredia. Drony sa často využívaju na nazbieranie RGB obrázkov ktoré sa neskôr pomocov algoritmu strojového videnia ako je AgiSoft Photoscan, PixčD alebo DroneDeploy používaju na vytvorenie RGB point cloudu, kde sa môže požiť vzdialenostná a objemová aproximácia.

3 Neural Network

3.1 History

V posledných rokoch, najlepšie systémy s aplikaciou umelej inteligencie - ako sú rozpoznávače reči v mobilných zariadeniach alebo automatické prekladače majú dobré výsledky v technike nazývajúcej sa "deep learning". Deep learning je v podstate iné meno pre aplikaciu umelej inteligencie s názvom Neural network, ktorý sa vyvýja takmer 80 rokov. NN boli prvý krát navrhnuté v roku 1944, dvoma výskumníkmi z Chicagskej univerzity, ktorí v roku 1952 prešli na MIT a založili oddelenie kognitívnych vied.

3.2 What is it

NN sú myslené na robenie strojového učenia, v ktorom sa počítač učí vykonávať úlohy na zákklade analyzovania trenovácich príkladov, ktore sú zvyčajne ručne oznaČene. Systém na rozpoznávanie objektov by mohol mať prístup k tisíckam obrázkov označených ako auto, dom, guľa a podobne. NN sieť hľada vizuálne paterny v obrázku ktoré koré majú vzajomný vzťah s konkretným označením. Voľne modelovaná NN na ľudskom mozgu má tisíce až milióny jednoduchých node, ktoré sú husto prepojené. Väčšina sieti sa dnes organizuje do vrstiev node a tie posielajú údaje vpred, čo znamená že dáta nimi prechádzaju iba v jednom smere. Jedna noda môže byť pripijená k viacerím nodam vo vrstvách pod ňou z ktorej príjma data a viacej node vo vrstve nad ňou kde spracované dáta posiela. Ku každemu vstupnému prepoju sa pridelí čislo známe ako "váha". Ak je sieť aktívna, noda príjme rôzne dáta z každého vstupu a vynásoby ich pridelenou váhou, potom všetky výsledky sčita ak je výsledne číslo pod treshold hranicou, noda nepošle žiadne dáta do ďalšej vrstvy. Ak čislo prekročuje treshold hodnotu, tak noda "výstrelí", čo znamená že pošle súčet vstupov na všetky výstupy. Keď sa NN trenuje, všetky váhy a tresholdy sú nastavené na náhoddnu hodnotu. Trénovacie data sú posielané do spodnej vstupnej vrstvy a prechádzaju cez nasledujúce vrstvy, nasobia sa a sčitavajú sa v zložitými cestami, pokiaľ radikálne transformované nedojdu na vrchnú vystupnu vrstvu. Počas tréningu sa váhy a prahove hodnoty neustále upravuju kým treningové údaje s podobnými štítkami neprinášajú podobne výstupy.

3.3 Vývoj

Neuronove siete opísane v roku 1944 mali váhy a treshold hodnoty, ale neboli usporiadané do vrstiev a výskumnici nešpecifikovali trénovaci mechanizmus. Výskumnici dokázali ukázať, že NN dokáže v princípe vypočítať hocijakú funkciu ako digitálny počítač. Výsledkom bola viac neurová veda ako počítačová a cieľom bolo poukázať, že ľudslý mozog môžme považovať za výpočtové zariadenie.[4]

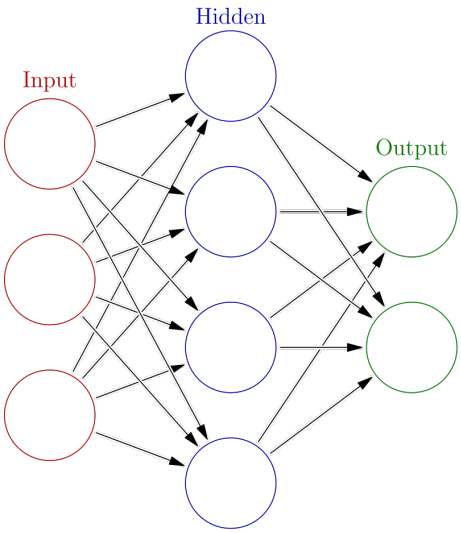

Obr. 3.1: Priklad neuronovej siete

4 RANSAC

4.1 Overview

RANSAC je algoritmus vytvorený Fischlerom a Bollesom, určuje všeobecný prístup k odhadu parametrov, s veľkym podielom outliers v stupnom datasete. Na rozdiel od iných výkonných algoritmov odhadu, ako napríklad M-estimators a meródov najmenších štvorcov s prepojením na strojové učenie. RANSAC bol vytváraný komunitov ľudi používajúci strojové učenie. RANSAC je vzorkovacia technika ktorá generuje kandidáta na minimalny pocet pozorovani potrebnych na zistenie odhadu parametrov leziacich pod modelom. Narozdiel od ostatných vzorkovacích algoritmov, ktoré používaju čo najviac bodov ako môžu, RANSAC používa najmenši počet bodov ako môže.

4.2 Algoritmus

1. Vybranie minimum náhodných bodov potrebných na určenie parametrov modelu
2. Vyriešenie parametrov pre model
3. Určenie koľko bodov z množiny všetkých bodov leží s preddefinovanou ϵ.
4. Ak zlomok bodov ležiacich v preddefinovanej ϵ, presahuje preddefinovaný prah τ, prehodnotí parametre modelu použitím všetkých identifikovaných inliers a ukonči.
5. Inak, opakuj kroky 1 až 4, s maximálnym N opakovaniami.

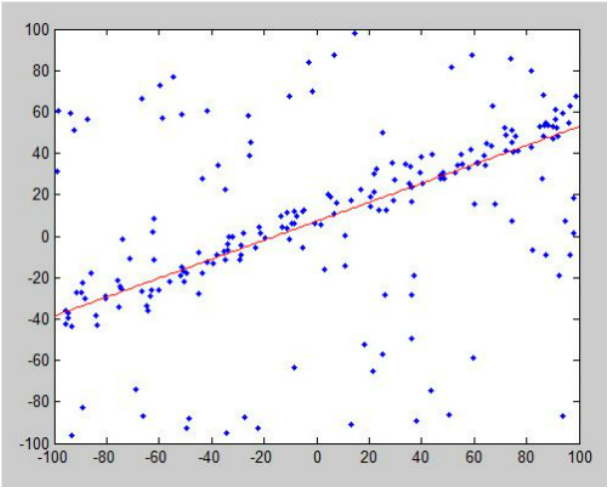

Obr. 4.1: Priklad algoritmu v 2D rovine

Modre sú body z datasetu, pomocou RANSAC algoritmu sa určili 2 body, ktoré majú vo svojom subsete najmenej bodov ležiacich mimo alfy.

4.3 RANSAC 3D

Podobne ako pri opise vyššie RANSAC 3D funguje s výberom náhodnych troch bodov na ktorých zostaví rovinu a spočita body ležiace v rovine a body ležiace mimo roviny. Algoritmus sa opakuje n-opakovaní a výstupom je najlepší model.

4.4 Neural guided RANSAC

5 KINECT

Kinect je vstupné zariadenie snímajuce pohyb, vyrobené Microsoftom. Zariadnei obsahuje RGB kamery a infračervený projektor a detektor ktorý monitoruje hĺbku priestoru na zaklade štrukturovateľného svetla alebo na zaklade času trvajúcemu svetlu dopadnuť na objekt, vďaka ktorému vie kinect poskytnúť rekognizáciu giest v reálnom čase. Kinect sa používa hlavne v hernom priemysle, ale používa sa taktiež na komerčné a akademické učely pretože poskytuje mapovanie priestoru a je lacnejši než profesionálne zariadenia.

Obr. 5.1: Kinect v2

5.1 Ako funguje

Infračervený projektor na kinevte posiela modulované infračervené svetlo ktoré je zachytené sensormy. Infračervené svetlo ktoré sa odrazí od bližších objektov ma kratší čas letu ako svetlo ktoré sa odrazí od vzdialenejších objektov, takže sensor sníma ako vymodulovaný vzor bol deformovaný z času letu svetla, pixel po pixeli. Čas príletu meranej hlbky touto metódov môže byť presnejšie vypočítany v kratšom čase, čo zabezpečí viac snímkov za sekundu. Hneď ako kinect naskenuje hlbkovú fotografiu, použije metódu zisťovania hrán k vytýčeniu bližších objektov z pozadia fotky.

5.2 Výstup z KINECTU

Na získanie výstupu z Kinectu je potrebné si nainštalovať Open-source knižnicu LibFreenect2, ktorá je určená na získavanie videi z Kinectu verzie 2. Knižnica disponuje vzorovým kódom, ktorý po spustení zapne Viewer a okno rozdelí na štyri časti a v nich uvidíme výstupy

Infra Red kamery, farebnej kamery a depth kamery. Nato aby sme knižnicu mohli používať potrebovali sme doinštalovať potrebné knižnice a súčasti. Na získanie snímky z Kinectu sme použili Python script, ktorý nám vytvorí point cloud súbor,v ktorom budeme hľadať požadovane tvary.

5.2.1 List potrebných Knižnic pre Ubuntu 22.04 LTS

- libusb
- TurboJPEG
- OpenGL
- OpenCL (optional)
- CUDA (optional, NVIDIA only)
- VAAPI (optional)
- OpenNI2

5.3 OpenNI 2.0

Open-source framework vytvorený spoločnosťou PrimeSense pre 3D Natural Interaction senzory od spoločnosti napríklad Asus Xtion, spoločnosť stojí za lincencovaným dizajnom hardwaru a čipov použiych priamo v Kinecte. Druhá verzia OpenNI sa oproti prvej ma znížiť zložitosť API tým že zložité funkcie sa presunuli do middlewaru a aby funkcie na komunikaciu so senzormi boli jednoduchšie na pochopenie a zároveň ma podporu pre generáciu Kinectu v2. OpenNI2 poskytuje prácu so surovými dátami z Kinectu. Rôzne vyššie funkcie ako sú sprcovanie gest, detekcie a sledovanie pohybov, rozpoznávanie tvarov je potrebné rozšíriť middleware, alebo použiť Microsoft SDK, ale nakoľko táto publikacia je spracuvaná na operačnom systéme Linux je potrebné použíť OpenNI2 SDK, ktoré by malo pracovať aj s inými druhmi kamier.[5]

5.4 PCD súbor

Pomocou OpenNI2 implementovaného v programovacom jazyku C++ a knižnicou PCL je nadviazaná komunikáia s Kinectom, ktorý streamuje dáta a sú vyobrazené v okne OpenNI2 a pomocou klávesy S vieme vyhotoviť PCD súbor potrebný na vyhľadavanie tvarou pomocou RANSAC algoritmu.

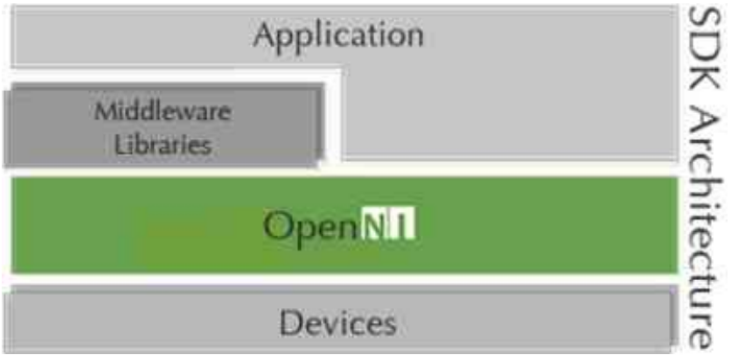

Obr. 5.2: Architektúra softwarového vývoja

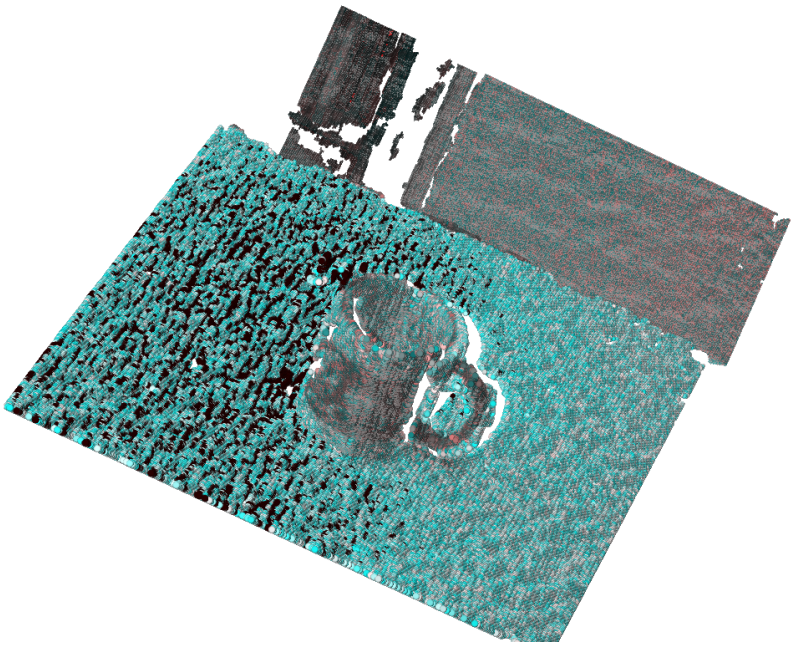

Obr. 5.3: Výstupný Point Cloud z Kinectu

6 Implementavanie RANSAC algoritmu

OTAZKA NA KONZULTANTA TREBA POPISOVAT MATEMATICKY KAZDY JEDEN MODEL ?
Kód: BakalarskaPraca/PCLTUTORIAL/cylinder.cpp
Budeme postupovat pomocou krokov:

1. PointCloudData .pcd súbor
2. Zvolenie geometrického modelu
3. Definovanie parametrov
4. implementovanie RANSACu
5. Point Cloud Binary Segmentation

[6]

6.1 1. PointCloudData

Pre praktickejšiu prácu s pointcloudom na začiatku odfiltrujeme všetky body ktoré su vzdialenejšie ako 1,5 metra a odhadneme normaly povrchu v každom bode. Odfiltrovaný model je uložený v samostatnm PCD súbore.

6.2 2. Zvolenie geometrického modelu

Vyberieme si geometricky model, čo bude zodpovedať trom náhodným bodom aby sme vedeli zostrojiť rovinu. V blízkosti roviny vo vopred definovanom tresholde spočítame koľko bodov leží v blízkosti roviny. Vyberieme rovinu ktorá ma najväčši počet inlierov ako najlepši model. Postup sa opakuje pokiaľ neprejde algoritmus presný počet interácii zvolených na začiatku. V kóde je zvolený model válca ktorý ma v 3D priestore predpis

$$f(x - a/c * z, y - b/c * z) = 0 \tag{6.1}$$

kde konštanty a,b,c sú zložky normálového vektora n', ktorý je kolmý na rovinu a ktorýkoľvke rovnobežný vektor s rovinou. Z toho nám vyplýva, že bod p=(x,y,z) patrí do roviny vektora n' ak spĺňa rovnicu.

6.3 3. Definovanie parametrov

V kóde sa na začiatku nastavili požadované hodnoty, čiže hľadany model v kóde nastavený na válec, vzdialenosť bodov pre vyhodnotenie RANSACA ako inlier 5cm, vplyv normál

na váhu 0.1 a nastavili limit modulu aby bol menší ako 10cm. Hodnoty treba na začiatku preskušať a vybrať ktoré maju najväčšiu presnosť alebo rýchlosť. je možne skúsiť automatické nastavovanie parametrov, čo by teoreticky mohlo fungovať na zaklade vypočítania strednej hodnoty vzdialenosti medzi susediacimi bodmi.

6.4 4.implementovanie RANSACu

- Finding a plane (1 opakovanie)
  Prv sa zvolia 3 body z PointCloudu, z ktorých sa má vytvoriť rovnica roviny najdením parametrov a,b,c,d. K ním sa dá dopracovať lineárnou algebrou, konkrétne krížovým súčinom dvoch vektorov ktoré generuju ortogonálny vektor. Treba definovať vektory z rovnakého bodu v rovine a vypočítať normálu k ním, ktorá definuje normalu roviny. Pomocou normal normalizujeme naš normalový vektor a získame parametre a,b,c a dopočítame parameter d čo je posun roviny od originu.

- Bod k rovine: definovanie tresholdu

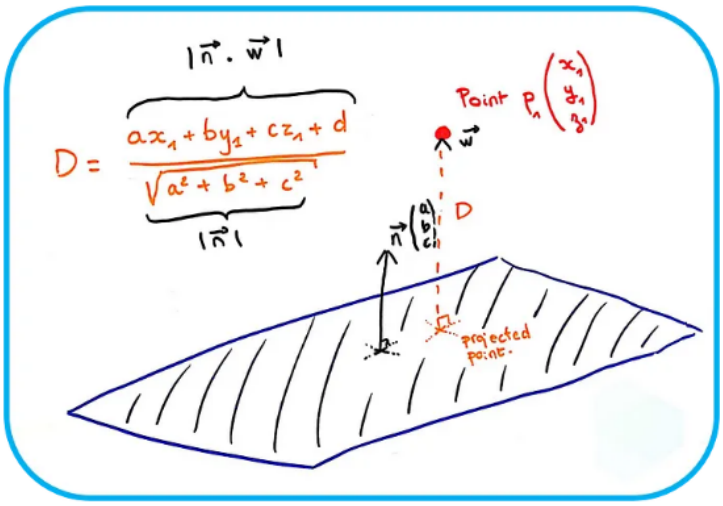

A normal n defines the plane, and we can see what the D distance point-to-plane we want to compute looks like. © F. Poux

Obr. 6.1: Dajake rovnice co treba prepocitat a prekreslit

Z obrázka 6.1 vyplýva, ak sa vyberie hociktorý bod mimo troch použitých na vytvorenie roviny, získame vzdialenosť bodu od roviny. Vzdialenosť sa porovnáva s treshholdom a vyhodnotí sa, či je bod inliers.

- Opakovanie Vytvorenie cyklu ktorý sa bude opakovať počet interacii a porovnávať, či aktuálny model je lepši než doteraz najlepší model a výstupom bude najlepší fitting RAN-

SAC model.

6.5 5. Vyzualizácia PointCloudu

Z predošleho kroku výstupom je set bodov ležácich v tresholde, ktoré sú zapísané do súboru pre vyhodnotenie výsledku.

7 Implementovanie RANSAC alfgoritmu s pouzitim NN

8 Vystupy

S použitím pointCloudu z obrázka 5.2 výstupom algoritmu so vstupným paramtrom na ziskávanie valca je vonkajšia a vnútorna rovina hrnčeka. Point cloud bol stiahnuty z internetu.

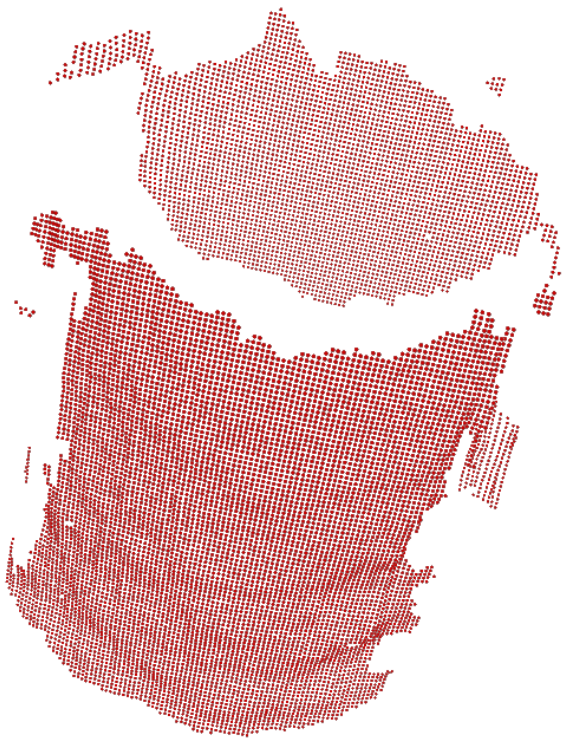

Obr. 8.1: Výstup algorimu RANSAC v knižnici PCL

8.1 POZNAMKA

Kinect ma horsie vzorkovanie oproti pouzitemu PCD cize aktualne pracujem na zdokonalovani spracovania vystupu Kinectu, pretoze na zlozitejsie tvary horsie spracuvava neda sa rozoznat tvar objektu a casto krat zapracuje aj okolite predmety do vypoctu co vyhodnocie zle vysledky. Musim upravit scenu pretoze skor ako nadobu v strede rozozna vlnovitu stenu ako valec.

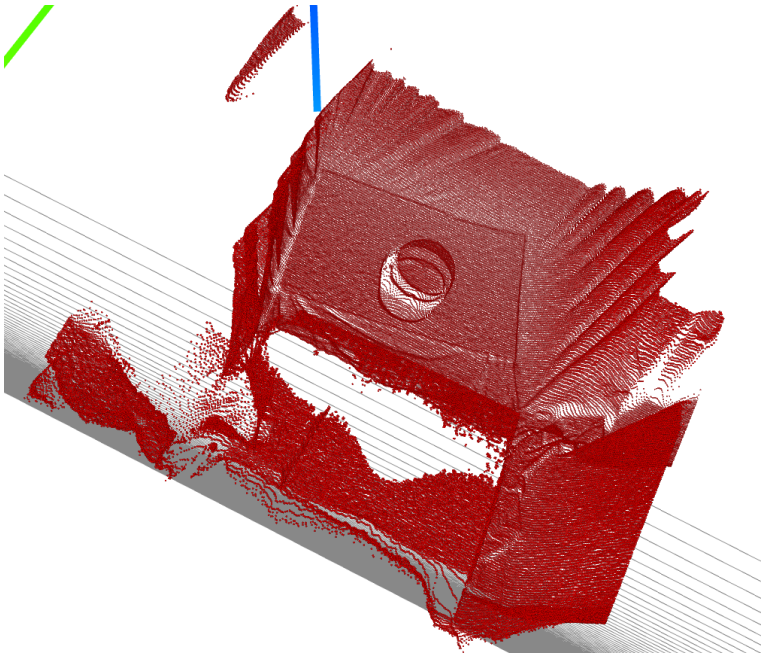

Obr. 8.2: Aktualny vystup z kinectu

9 Recitácia

Citujem všetky zdroje v **bibliography.bib**, [4, 2, 1, 5, 3, 6].
Good luck.

10 Kod = neaktualne

```
from freenect2 import Device, FrameType
import numpy as np

# Open the default device and capture a color and depth frame.
device = Device()
frames = {}
with device.running():
   for type_, frame in device:
      frames[type_] = frame
      if FrameType.Color in frames and FrameType.Depth in frames:
         break

# Use the factory calibration to undistort the depth frame and register the RGB
# frame onto it.
rgb, depth = frames[FrameType.Color], frames[FrameType.Depth]
undistorted, registered, big_depth = device.registration.apply(
   rgb, depth, with_big_depth=True)

# Combine the depth and RGB data together into a single point cloud.
with open('output.pcd', 'wb') as fobj:
   device.registration.write_pcd(fobj, undistorted, registered)

with open('output_big.pcd', 'wb') as fobj:
  device.registration.write_big_pcd(fobj, big_depth, rgb)
```

Výpis 1: Vytvorenie PCD pomocou Kinectu

Záver

Conclusion is going to be where?
Here.

Zoznam použitej literatúry

1. *Point cloud library*. Dostupné tiež z: https://pointclouds.org/.
2. RADU BOGDAN RUSU, Steve Cousins (zost.). *Point cloud library (pcl): 3D is here*. 2011 IEEE international conference on robotics a automation: IEEE. Dostupné tiež z: https://scholar.google.com/citations?view_op=view_citation&hl=en&user=U_NEZHQAAAAJ&citation_for_view=U_NEZHQAAAAJ:u-x6o8ySG0sC.
3. – SA ZMENI, wikipedia (zost.). *Point cloud*. https://en.wikipedia.org. Dostupné tiež z: https://en.wikipedia.org/wiki/Point_cloud.
4. HARDESTY, Larry (zost.). *Explained: Neural networks: metodický materiál pro autory vysokoškolských kvalifikačních prací* [online]. MIT: MIT News Office, 2014-04-14 [cit. 2014-04-14]. Dostupné z : https://news.mit.edu/2017/explained-neural-networks-deep-learning-0414.
5. FAIRHEAD, Harry (zost.). *OpenNI 2.0 - Another Way To Use Kinect* [online]. i-programmer.info, 2012-12-22 [cit. 2012-12-22]. Dostupné z : https://www.i-programmer.info/news/194-kinect/5241-openni-20-another-way-to-use-kinect.html.
6. FLORENT POUX, Ph.D. (zost.). *3D Model Fitting for Point Clouds with RANSAC and Python: A 5-Step Guide to create, detect, and fit linear models for unsupervised 3D Point Cloud binary segmentation: RANSAC implementation from scratch.* Towards Data Science. Dostupné tiež z: https://towardsdatascience.com/3d-model-fitting-for-point-clouds-with-ransac-and-python-2ab87d5fd363.